

김민수



010-7714-9201



vibrio0102@gmail.com



linkedin



github

요약

온프레미스 Kubernetes 위에 MLOps 플랫폼을 혼자 설계·구축·운영하는 엔지니어입니다. HUINNO에서 6개월간 수집 → 레이크하우스 → 변환 → 계보 → 분산 학습 → 실험·모델 레지스트리까지 전 구간을 Pulumi(Python IaC)로 코드화했고 플랫폼 2인 팀에서 클러스터 구성은 단독으로 맡았습니다. 도구를 늘리기보다 사람이 병목인 자리를 찾아 없애는 쪽을 택하고, 결정은 실측으로 내립니다. 그 전에는 iOS 개발자로 시작해 백엔드·프론트·클라우드 데이터 파이프라인을 거쳐 데이터 엔지니어링 팀을 리드했습니다.

핵심 성과 (2026-09 실측)

인프라 전체를 코드로 — 수집부터 모델 저장소까지 12개 Pulumi 스택으로 나눠 인프라를 고쳐도 PR로 남고 새 환경은 스택만 골라 다시 세울 수 있게 함. (직접 작성: 스택 코드 변경 93%(6개는 96% 이상) · 저장소 커밋 1,204건 중 92% · 머지 PR 678건)

10노드 · 상시 pod 235개 · 사내 서비스 23종을 프로덕션 운영. 23종 전부에 Dex(GitHub OIDC) + oauth2-proxy SSO를 적용하고 같은 신원을 Kubernetes RBAC 까지 연결.

데이터셋 준비를 한 사람에게 기대지 않게 — 담당자에게 부탁하고 기다리던 일을 Airflow 3.x + dbt + Apache Iceberg가 정해진 때에 알아서 돌리게 바꾸고 DataHub에 출처를 자동으로 남겨 연구자가 직접 찾아 쓰게 함. (직접 작성: ETL 저장소 커밋 1,599건 중 83% · 공용 프레임워크 93% · CAST · MIMIC-IV · 운영 파이프라인 각 100%)

학습 데이터 전달 25배 단축 — 네트워크·스토리지 재설계로 iperf3 실측 93.7 Mbps → 2.5 Gbps, 8TB 기준 8.4일 → 7.8시간.

GPU 증설 결정을 실측으로 전환 — 10일 측정 결과 가동률 5.3% · 대기 0건, 병목은 유휴 세션이 점유한 1,112 GPU-시간(점유의 91%). 구매 대신 할당 회수로 방향을 바꿈.

AI 에이전트를 상시 투입해 1인 처리량을 팀 규모로 — 그 속도를 SDK 단위 테스트 719건 · CI 게이트 · 실패 기록 23건 · PRD 30건으로 받침.

이전 경력: AWS EMR/PySpark 미술 시장 ETL 파이프라인 총괄(Eazel, 팀 리드).

현재 하는 일

HUINNO Data Engineer (2025.12 -). 베어메탈 Kubernetes 위 MLOps 플랫폼 전 층(네트워크 · 스토리지 · 카탈로그 · 계보 · 오케스트레이션 · 분산 학습 · 신원)을 운영하면서 연구 코드가 KubeRay 분산 학습으로 옮겨오도록 재현성 계약(데이터셋에 버전 · 내용 해시 · 코드 커밋 · 환경 lock · 시드를 실행 시점에 기록)과 MLflow 트래킹·모델 레지스트리를 붙이는 중입니다. 기존 연구 워크플로를 정량 조사해 「결과에 좌표가 없다」는 원인을 특정한 것이 이 설계의 출발점입니다. 「도메인 ETL은 연구자가, 실행 · 계보 · 검증 · 재시도는 플랫폼이」 맡는 분담을 정착시키고 있습니다.

기술 스택

플랫폼: Kubernetes(kubeadm) · Pulumi · Cilium · SeaweedFS · Dex/OIDC · Prometheus/Grafana

데이터: Airflow 3.x · dbt · Apache Iceberg · DataHub · PostgreSQL(pg_duckdb) · ClickHouse

ML: Ray/KubeRay · MLflow · PyTorch · DVC

언어·기타: Python · SQL · Swift · Shell · AWS/GCP · LangChain

자격증 · 어학

자격증: 정보처리기사 (2017.11) · 정보처리운용기능사 (2009.07) · 한국산업인력공단

어학: 한국어 원어민 · 영어 AL (OPic) · 일본어 일상 회화

경력 · 프로젝트 상세는 별도 문서(resume_korean.pdf)에 있습니다.